

데이터 사이언스 개론 기말 발표

슬라이드 1

안녕하세요. 10조 발표를 맡은 구화중입니다. 저희의 주제는 “베스트셀러 키워드 변화로 한국 사회의 흐름을 읽을 수 있는가?”이구요. 바로 발표 시작하겠습니다.

슬라이드 2

발표 내용은 다음과 같은데요. 저희가 이 주제로 본 연구를 시작하게 된 이유를 리마인드하고, 일정에 따라 수행한 과정을 순차적으로 말씀드리겠습니다.

슬라이드 3

먼저 저희는 사서들이 핵심 업무 중 하나인 장서 개발을 할 때, 이용자의 선호를 파악하기 위해서 출판사 베스트셀러 목록을 참고한다는 점에 집중했습니다. 따라서 본 연구는 출판사의 베스트셀러 목록을 통해 이용자의 선호가 반영된 이 사회의 분위기를 파악할 수 있는지, 그리고 이용자 선호가 실제로 사회 분위기를 반영하는지 분석하고자 했습니다.

슬라이드 4

전체적인 일정은 다음과 같고, 일정에 따라 어떤 변화가 있었는지 살펴보도록 하겠습니다.

슬라이드 5

5월 첫째주에는 데이터 분석 계획에 대한 여러 학우분들의 질문을 반영하여 연구 시기를 조정하고, 스테디셀러와 시차 지표 적용 범위에 대한 정의를 재정립하는 등 계획을 일부 수정하였습니다. 만약 학우분들이 어떤 질문을 하셨는지 궁금하시다면? 저희 조 게시판을 참고하시면 되겠습니다.

슬라이드 6

또 교수님의 피드백을 반영해 연구 범위를 기존 11개년에서 6개년으로 대폭 축소하였습니다.

슬라이드 7

이때 데이터 수집과 분석 중간점검을 위해 팀원별로 파트를 맡아 2025년만, 수집과 분석을 진행해보았습니다.

슬라이드 8

첫 번째로, 사회적 상황을 분석하기 위한 빅카인즈 분석입니다. 제가 맡아서 진행한 부분인데요. 2025년만 먼저 분석해보기로 했지만 사회적 흐름을 전체적으로 보고 싶어 2020년에서 25년까지 데이터를 수집하기로 결정했습니다. 빅카인즈를 활용한 데이터 수집은 검색어를 입력하지 않으면 1년 단위밖에 검색이 되지 않아서 1년 단위로 끊어서 수집을 했는데요. 검색어를 입력하지 않으면 사용할 수 있는 기능이 제한되기도 하고, 특정 검색어에 대한 수집이 아니라 해당 연도에 어떤 검색어가 있는지에 대한 데이터 수집이 목적이었다는 점에서 빅카인즈를 활용한 분석이 본 연구에는 부적절하다는 결론을 내렸습니다.

슬라이드 9

두 번째로, 교보문고를 활용한 분석입니다. 베스트셀러 순위와 서지사항 등을 기록한 csv 파일을 만든 뒤 파이썬과 라이브러리들을 통해 그래프로 구현해 시각화했습니다. 그 결과

슬라이드 10

베스트셀러 카테고리의 분포가 소설, 인문, 경제/경영 등의 순으로 많은 것을 확인해볼 수 있었습니다.

슬라이드 11

세 번째로는 정보나루를 활용한 분석인데요. 교보문고와 정보의 결이 비슷하기 때문에 교보문고 분석과 마찬가지로 csv 파일을 만든 뒤 파이썬으로 분석을 진행했고 이를 통해 인기대출도서 KDC 분포는 문학이 가장 많음을 확인할 수 있었습니다.

슬라이드 12

저희는 각자 파트를 분석한 후, 개인적으로 보고서를 작성해 공유했습니다. 지금 보시는 건 그 보고서의 일부인데요. 방금 앞에서 정보나루와 교보문고의 정보의 결이 비슷하다고 했죠. 이 두 분석에서 어려웠던 점은 KoNLPy를 활용한 명사 추출 과정에서 예상과는 다른 결과가 반복적으로 도출이 되었다는 것이었습니다. 따라서 불용어 목록을 여러 차례 수정하고 추가하는 과정을 반복했고, 전처리 코드를 여러 번 수정하는 등 보완하면서 결과를 개선해나갔습니다.

슬라이드 13

이렇게 중간점검을 해본 뒤 5월 두~셋째주부터 본격적인 데이터 전처리를 시작했습니다. 이때 최종적인 연구 범위를 2020년부터 2024년까지 5개년으로 확정지었는데요. 이는 6개년보단 5개년으로 묶는 것이 깔끔하고, 또 2025년은 비교적 최근 연도이기 때문에 2024년까지 하는 것이 데이터 수집에 용이할 것 같다는 판단 하에 결정되었습니다.

슬라이드 14

저희는 계획 보고서에서 총 세가지의 가설을 세웠기에 팀원별로 각각의 가설에 맞는 분석을 실시하기로 했습니다. 먼저 사회적 이슈와 관련된 가설 1을 증명하기 위해서, 네이버 데이터랩을 이용해 키워드를 추출한 뒤 빅카인즈에 적용해 입력한 키워드를 검증하려는 계획을 세웠습니다. 앞서 설명드렸듯 빅카인즈에는 검색어를 입력해야 했던 치명적인 단점이 있었기에 검색어를 추출해 적용하는 방식으로 보완하고자 하였습니다.

슬라이드 15

그러나 네이버 데이터랩도 분야별 인기 검색어밖에 볼 수가 없고, 오래전 기록을 볼 수 없다는 단점이 발견되어 구글 트렌드로 키워드 추출 원천을 변경하게 되었습니다.

슬라이드 16

사실 구글 트렌드도 연도별로 카테고리 항목이 달라진다는 단점이 있긴 했으나 이는 연도별로 이슈가 다르기 때문에 카테고리도 매년 달라지는, 즉 사회적 분위기를 반영하는 것으로 받아들였습니다.

슬라이드 17

이후 구글 트렌드를 통해 수집한 데이터들을 직접 엑셀로 정리하고,

슬라이드 18

해당 파일을 통해 키워드를 추출해보았습니다. 클로드 AI를 활용하여 키워드 가중치를 분석하는 코드를 요청하고 이를 구글 코랩으로 시행했으며, 각 연도에서 점수가 가장 높은 키워드를 빅카인즈에 검색해보았습니다. 여기서 가중치 분석이란 카테고리별로 순위에 따라 가중치를 더하는 방식입니다. 원래는 단순 횟수를 세어 키워드를 추출하고자 했지만 데이터 양이 적어 유의미한 결과가 나오지 않았기 때문에 가중치 분석 방식을 채택했습니다.

슬라이드 19

지금 보시는 자료들은 분석의 일부분인데 이후 나올 데이터 분석 부분에서 문제와 함께 더 자세히 살펴보도록 하겠습니다.

슬라이드 20

이제 가설 2를 증명하기 위해 교보문고 데이터를 분석 및 활용하였고, 이를 통해 텍스트 정제를 시행하고, 형태소를 분석하고 추출한 다음 KDC 분류별 점유율, 연도별 Jaccard 유사도, 교보문고-정보나루 유사도를 산출했습니다.

슬라이드 21

마지막으로 가설 3을 증명하기 위해서는 정보나루 데이터를 활용했는데 이를 통해 KDC 분류, 핵심 키워드, Jaccard 유사도 분석에 사용할 수 있는 데이터 항목을 구조화했습니다. 사실 계획서를 쓸 때만 해도 '직접 할 수 있을까?'란 생각이 많은 부분을 차지했는데, 실제로 되긴 하더라고요.

슬라이드 22

이렇게 전처리를 마치고, 5월 셋째주 부터 가설 분석에 본격적으로 돌입하게 됩니다. 다음은 저희 계획서의 일부고요.

슬라이드 23

가설 1. '메르스, 촛불집회, 코로나 등 어떠한 굵직한 사건이 있을 때의 베스트셀러 키워드의 흐름이 그 사건의 흐름을 따라간다.'는 결국 성립되지 않는 것으로 나타났습니다. 2020년부터 2024년의 빅카인즈 키워드를 반영한 도서는 교보문고와 정보나루 데이터 모두에서 확인이 되지 않았는데요. 앞에서 저희가 구글 트렌드에서 사회 흐름의 키워드를 추출했다고 했죠. 구글 트렌드는 구글 검색량 기반 데이터이기 때문에 네이버 검색 점유율이 압도적인 한국 환경에서는 국내 이슈를 완전히 대표하지 못하는 플랫폼 편향이 존재하기 때문이라 볼 수 있습니다. 실제로 2024년 한강 노벨문학상 수상과 같은 국내 주요 이슈가 구글 트렌드에는 포함되지 않은 것이 대표적 사례이구요.

슬라이드 24

덧붙여서 코로나 직후 경제, 투자 도서의 수가 목록 top10에 들긴 했어도 그 수가 미미했다는 점 등을 보면 가설 1번은 성립하지 않는 것을 확인할 수 있었습니다. 이대로는 아쉬워서 2024년 핵심 키워드를 저희가 임의로 '한강'으로 설정을 하고 다시 분석해봤는데요. 그랬더니 사회적 흐름 관련 도서 top10에 등장했습니다. 그러나 이런 행태도 이 연도에만 한정되었기 때문에 최종적으로 가설1이 성립하지 않는다고 결론지었습니다.

슬라이드 25

다음으로 가설 2. '큰 흐름은 굵직한 사건과 같이 나타나더라도, 베스트셀러 키워드를 자세히 살펴 보았을 때는 연관성이 잘 보이지 않아 유의미한 결론이 도출되지 않는다.'입니다. 예를 들어 꾸준히 대중들의 선택을 받은 스테디셀러가 베스트셀러 목록에 포함된 경우, 사회 분위기와 무관할 가능성이 있습니다. 또 시대가 바뀌어도 변하지 않는 가치가 분명 존재하므로 시대적 요구라고 보기는 어려운 부분도 있고요. 따라서 스테디셀러 포함 여부에 따른 비교와 분석을 시행해 이와 같은 영향력을 구분하기로 했습니다.

분석 결과 교보문고 목록에서 스테디셀러를 제외했을 때와 하지 않았을 때의 차이가 크게 있지 않았고, 정보나루에서는 키워드 다양성 자체가 낮게 나타났습니다. 이는 연도간 Jaccard 유사도를 비교해보았을 때 정보나루가 교보문고의 약 2배 수준이었음을 본다면 시리즈 도서의 반복적인 대출 효과임을 알 수 있습니다.

슬라이드 26

따라서 가설 2는 부분적으로 입증되었다고 할 수 있습니다. 교보문고 데이터에서 사회 이슈가 베스트셀러 키워드에 일부 반영되는 경향이 확인되었으며, 스테디셀러를 제외하더라도 동일한 패턴이 유지되었기 때문입니다. 이는 사회 이슈 반영이 스테디셀러의 영향이 아닌 트렌드 도서에서 주로 발생하고 있음을 의미하는 것이라고 볼 수 있습니다.

슬라이드 27

마지막으로 가설 3. '영향을 미치는 분야가 있고 그렇지 않은 분야가 있다.'입니다. 도서 목록을 KDC 분야별로 매칭하였을 때 사회과학과 문학은 유의미한 반응이 있었으나 나머지 분야에서는 유의미한 반응이 나오지 않아 가설이 성립한다고 볼 수 있습니다. 다만, 사회과학은 경제와 투자 이슈에, 문학은 한강 작가의 노벨상 이슈에 크게 반응한 것으로 보아 이슈의 종류가 분야의 종류에 영향을 미친다고 할 수 있습니다.

슬라이드 28

AI 활용은 다음과 같으니 참고하시면 되겠습니다.

슬라이드 29

저희가 준비한 내용은 여기까진데, 혹시 질문 있으신가요?

질문이 (더) 없으시면 이상으로 발표를 마치겠습니다. (경청해주셔서) 감사합니다!